

Projet Visualisation de l'information, Données, utilisateurs et tâches

Groupe. Quentin ELLEON, Jim LAINEL, Alexandre LARGUECH, Gabriel LOIRAT

1. Jeu de données

Student Alcohol Consumption (Kaggle, miroir du dataset UCI *Student Performance*, Cortez & Silva, 2008). Questionnaires et bulletins de deux lycées portugais (Gabriel Pereira, Mousinho da Silveira), année 2005–2006.

Le jeu de données comprend deux tables de même structure, une pour les mathématiques (395 élèves) et une pour le portugais (649 élèves), 33 attributs, aucune valeur manquante. Dans la taxonomie de Munzner, c'est une table où chaque item est un élève dans une matière donnée.

Les 33 attributs se répartissent en trois types, 17 nominaux (sexe, école, milieu urbain/rural, métier des parents, soutien scolaire, projet d'études supérieures...), 10 ordinaux sur des échelles 1–5 ou 0–4 (éducation des parents, temps d'étude, sorties, consommation d'alcool, santé...), et 6 quantitatifs (âge, échecs passés, absences, notes G1, G2, G3 sur 20). Près de la moitié des attributs ne sont donc pas ordonnables, ce qui pèse directement sur le choix des techniques (§4).

Quelques limites à noter. 53 élèves ont G3 = 0 et 0 absence, mais ce sont en réalité des élèves non évalués codés par défaut, pas de vraies notes nulles, il faudra pouvoir les exclure de l'analyse. Alcool, sorties et temps d'étude sont auto-déclarés, donc sujets à un biais de déclaration. Les données étant observationnelles, on ne montre que des associations, jamais des causes. Et comme c'est un historique anonymisé, l'outil reste un démonstrateur pédagogique, pas un vrai outil de suivi d'élèves.

2. Utilisateurs

Profil	Expertise du domaine	Littératie en visualisation	Besoin
U1, Équipe pédagogique (enseignants, CPE, direction)	Élevée	Moyenne	Repérer les profils à risque, décider où placer le soutien. Accepte des vues denses et interactives.
U2, Parents / élèves	Faible	Faible	Comprendre ce qui est associé à la réussite, dans une logique de prévention. Besoin de vues simples, d'un vocabulaire non technique et de l'effectif n toujours affiché.

3. Tâches visuelles / analytiques (action → cible, Munzner)

U1, Équipe pédagogique

#	Action → cible	Tâche concrète	Idiome
1	Discover → correlation	Quels facteurs sont le plus associés à une note finale basse ($G3 < 10$) ?	Matrice de corrélation, coordonnées parallèles
2	Compare → distribution	Comparer la distribution de G3 entre sous-groupes (sexe, école, milieu, matière)	Boxplots en small multiples
3	Locate → outliers	Isoler les élèves cumulant plusieurs facteurs de risque (≥ 1 échec passé, absences élevées, trajet long, pas de projet d'études supérieures)	Coordonnées parallèles + brushing
4	Lookup → features	Consulter le profil complet d'un élève et le situer par rapport à la moyenne de son école et de sa matière	Panneau de détail, dumbbell chart
5	Identify → trend	Suivre la trajectoire $G1 \rightarrow G2 \rightarrow G3$ pour détecter un décrochage en cours d'année	Slope graph

U2, Parents / élèves

#	Action → cible	Tâche concrète	Idiome
1	Summarize → distribution	Voir comment les notes sont réparties et ce qu'est une note « habituelle »	Histogramme avec seuil de réussite (10/20)
2	Locate → position	Situer un profil saisi (fictif) dans la distribution, sans comparaison nominative	Histogramme + marqueur
3	Discover → dependency	Comprendre le lien entre sorties, alcool et notes sans jargon	Barres de moyennes par niveau, n affiché
4	Compare → features	Comparer un profil « à risque » et un profil « protégé »	Deux fiches côte à côte / dumbbell
5	Explore → trend	Faire varier un facteur (temps d'étude, sorties) et voir la note moyenne des élèves qui ont ce profil (association, non causalité)	Sliders + graphique lié

4. Techniques de visualisation par membre et compatibilité

Membre	Technique (D3)	Types de données pris en charge	Tâches couvertes	Compatibilité / limites
Quentin ELLEON	Coordonnées parallèles + brushing	Quantitatifs et ordinaux en axes ; nominaux en couleur	U1-1, U1-3, U1-2	Adaptée au multivarié. Limites, overplotting (≈ 650 lignes $\rightarrow$ transparence), axes ordinaux discrets (décalage aléatoire pour éviter la superposition, et étiquettes textuelles), nominaux non placés en axe.
Jim LAINEL	Matrice de corrélation	Quantitatifs et ordinaux (Spearman)	U1-1, U2-3	Vue d'ensemble des 16 attributs ordonnables. Limite, les nominaux sont exclus, montre des associations, pas des causes.
Alexandre LARGUECH	Small multiples de boxplots / strip plots	G3 (quantitatif) par groupe nominal ou ordinal	U1-2, U2-1, U2-3, U2-4	Compare des distributions et pas seulement des moyennes. n affiché obligatoire (certains groupes ont moins de 10 élèves).
Gabriel LOIRAT	Slope graph G1 $\rightarrow$ G2 $\rightarrow$ G3 + panneau de profil	Quantitatifs ordonnés dans le temps ; tous types dans le panneau	U1-4, U1-5, U2-2	Niveau « détail » naturel. Limite, seulement 3 points temporels.

L'organisation suit une logique overview + détail. La vue d'ensemble utilise les coordonnées parallèles ; un clic sur un élève ouvre le détail (panneau de profil). Deux filtres communs s'appliquent, la matière (changement de dataset) et l'inclusion ou l'exclusion des élèves non évalués. On garde aussi deux règles d'honnêteté, l'axe G3 reste toujours de 0 à 20, et les deux matières ne sont jamais cumulées dans une même vue.